

Midiendo la Sorpresa: La Divergencia de Kullback–Leibler y su Papel en el Aprendizaje Automático

Brandon Cereceda Silva
Facultad de Ingeniería
Universidad Autónoma del Estado de México (UAEMex)
Toluca, Estado de México, México

Resumen—La Divergencia de Kullback–Leibler (KL), también conocida como entropía relativa, es una herramienta matemática fundamental en la teoría de la información y el aprendizaje automático. En este artículo de divulgación se explica de manera intuitiva y pedagógica qué mide la divergencia KL mediante un ejemplo cotidiano: el clasificador de correo no deseado (*spam*). Se analiza su relación matemática con la entropía cruzada, se desglosan exhaustivamente los componentes de cada ecuación, se presenta un ejemplo numérico paso a paso y se ilustra por qué su propiedad de no simetría resulta determinante al entrenar algoritmos de inteligencia artificial.

Index Terms—Divergencia de Kullback–Leibler, entropía cruzada, teoría de la información, filtro de spam, aprendizaje automático, optimización.

I. INTRODUCCIÓN E INTUICIÓN COTIDIANA

En la vida digital cotidiana, interactuamos continuamente con sistemas que toman decisiones probabilísticas. Un ejemplo clásico es el filtro de correo no deseado (*spam*). Cuando un correo electrónico arriba a la bandeja de entrada, existen dos perspectivas probabilísticas en juego:

1. **La realidad empírica u objetiva (P):** Es la verdad absoluta del correo. Si el mensaje es efectivamente fraudulento o no deseado, la probabilidad real es $P(\text{spam}) = 1$ y $P(\text{legítimo}) = 0$.
2. **La hipótesis o creencia del algoritmo (Q):** Es la estimación numérica calculada por el modelo a partir de las palabras y remitente (p. ej., asignando $Q(\text{spam}) = 0.80$ y $Q(\text{legítimo}) = 0.20$).

Si el modelo fuese perfecto, su creencia coincidiría exactamente con la realidad ($Q = P$). No obstante, en la práctica siempre existe una discrepancia. La **Divergencia de Kullback–Leibler (KL)** [1] mide precisamente el grado de “sorpresa”, ineficiencia o pérdida de información que ocurre al describir la realidad P mediante la aproximación imperfecta Q .

II. DEFINICIÓN DE LA DIVERGENCIA KL Y DESGLOSE DE TÉRMINOS

Propuesta originalmente en 1951 por Solomon Kullback y Richard Leibler, la divergencia KL cuantifica la penalización promedio que sufrimos al usar un modelo de probabilidades Q en lugar de la distribución auténtica P [2]. Para variables aleatorias discretas, se define formalmente como:

$$D_{\text{KL}}(P \parallel Q) = \sum_{x \in \mathcal{X}} P(x) \log \left(\frac{P(x)}{Q(x)} \right) \quad (1)$$

Significado detallado de los términos de la ecuación (1):

- $D_{\text{KL}}(P \parallel Q)$: Valor escalar no negativo que representa la divergencia de Q respecto a P (medida en bits si el logaritmo es en base 2, o en nats si es natural).
- $\mathcal{X}$: Espacio muestral o conjunto de todas las categorías posibles (en nuestro ejemplo, $\mathcal{X} = \{\text{spam}, \text{legítimo}\}$).
- x : Cada una de las categorías o eventos individuales dentro del espacio $\mathcal{X}$.
- $P(x)$: Probabilidad real de ocurrencia del evento x en el mundo físico.
- $Q(x)$: Probabilidad estimada por el modelo de que ocurra el evento x .
- $\frac{P(x)}{Q(x)}$: Razón de probabilidades. Si el modelo es exacto ($Q(x) = P(x)$), la razón es igual a 1, haciendo que su logaritmo sea cero.
- $\log \left(\frac{P(x)}{Q(x)} \right)$: Factor de discrepancia individual. Representa la sorpresa o costo informativo adicional que introduce el modelo para el evento x .
- $\sum_{x \in \mathcal{X}} P(x) [\dots]$: Esperanza matemática bajo la distribución verdadera P . Pondera la penalización de cada evento según qué tan frecuente es en la realidad.

Por la desigualdad de Jensen y el teorema de Gibbs, se garantiza que:

$$D_{\text{KL}}(P \parallel Q) \geq 0 \quad (2)$$

donde $D_{\text{KL}}(P \parallel Q) = 0$ ocurre si y solo si $P(x) = Q(x)$ para todo evento $x \in \mathcal{X}$.

III. CONEXIÓN CON LA ENTROPÍA CRUZADA

En el entrenamiento de modelos de clasificación y redes neuronales, la divergencia KL se vincula de manera directa e inseparable con la entropía de Shannon y la entropía cruzada.

III-A. Entropía de Shannon: $H(P)$

Mide la cantidad intrínseca de incertidumbre o desorden contenida en la propia naturaleza de los datos reales:

$$H(P) = - \sum_{x \in \mathcal{X}} P(x) \log P(x) \quad (3)$$

- $H(P)$: Límite teórico mínimo e irreducible de información necesario para describir la realidad P .
- $-\log P(x)$: Cantidad de auto-información o sorpresa inherente al evento x .

III-B. Entropía Cruzada: $H(P, Q)$

Mide el costo total promedio en bits que se paga al codificar los eventos generados por la realidad P utilizando el esquema propuesto por el modelo Q :

$$H(P, Q) = - \sum_{x \in \mathcal{X}} P(x) \log Q(x) \quad (4)$$

- $H(P, Q)$: Costo total de codificación bajo el modelo imperfecto Q .
- $-\log Q(x)$: Longitud del código o penalización asignada por el modelo Q al evento x .

III-C. La Identidad Fundamental de Descomposición

Expandiendo algebraicamente el logaritmo de un cociente en (1), obtenemos:

$$\begin{aligned} D_{KL}(P \parallel Q) &= \sum_x P(x) \log P(x) - \sum_x P(x) \log Q(x) \\ &= -H(P) + H(P, Q) \end{aligned} \quad (5)$$

Reordenando los términos, se deduce la relación universal:

$$H(P, Q) = H(P) + D_{KL}(P \parallel Q) \quad (6)$$

Interpretación intuitiva: El costo total asumido por el modelo ($H(P, Q)$) es igual a la incertidumbre inherente de los datos ($H(P)$) más el costo adicional provocado por la imperfección del clasificador ($D_{KL}(P \parallel Q)$).

III-D. Equivalencia en Optimización de Aprendizaje Automático

Dado que el conjunto de datos de entrenamiento (P) no cambia durante el entrenamiento, la entropía real $H(P)$ es una constante fija. En consecuencia:

$$\arg \min_{\theta} H(P, Q_{\theta}) \equiv \arg \min_{\theta} D_{KL}(P \parallel Q_{\theta}) \quad (7)$$

- θ : Vector de parámetros internos (pesos y sesgos) ajustables del algoritmo.
- Q_{θ} : Distribución predicha por el modelo parametrizado por θ .
- $\arg \min_{\theta}$: Operador de optimización que busca la configuración de parámetros θ que produce el mínimo error posible.

Por tanto, minimizar la pérdida por entropía cruzada durante el entrenamiento supervisado equivale formalmente a minimizar la divergencia KL entre la verdad y la predicción del modelo [3].

IV. ASIMETRÍA DE LA DIVERGENCIA KL

A diferencia de una distancia geométrica convencional (donde la distancia de A a B es idéntica a la de B a A), la divergencia KL no es simétrica:

$$D_{KL}(P \parallel Q) \neq D_{KL}(Q \parallel P) \quad (8)$$

Esta propiedad genera dos comportamientos cualitativamente opuestos según el sentido del cálculo:

IV-A. Divergencia hacia adelante ($D_{KL}(P \parallel Q)$)

Denominada también divergencia inclusiva o *zero-avoiding*:

- Si un evento ocurre en la realidad ($P(x) > 0$), pero el modelo predice erróneamente probabilidad nula ($Q(x) \rightarrow 0$), la penalización matemática se dispara a infinito ($\log(P/0) \rightarrow \infty$).
- En el filtro de spam, esto significa que el algoritmo recibe un castigo desmesurado si asume como “imposible” una palabra que sí aparece en correos legítimos. Esto obliga al modelo a extender sus probabilidades sobre todo el soporte de P .

IV-B. Divergencia hacia atrás ($D_{KL}(Q \parallel P)$)

Denominada divergencia exclusiva o *zero-forcing*:

- La ponderación está dominada por $Q(x)$. Si $P(x) = 0$, el modelo prefiere fijar $Q(x) = 0$ para no pagar costo alguno, concentrándose únicamente en una de las modas principales de la distribución.

V. EJEMPLO NUMÉRICO DEMOSTRATIVO

Para ilustrar el cálculo y la asimetría de forma concreta, consideremos un servidor de correo con dos categorías $\mathcal{X} = \{\text{spam}, \text{legítimo}\}$.

Supongamos que la distribución real de tráfico en el servidor es:

- $P(\text{spam}) = 0.90$
- $P(\text{legítimo}) = 0.10$

El clasificador evalúa un lote de correos y estima las siguientes probabilidades:

- $Q(\text{spam}) = 0.80$
- $Q(\text{legítimo}) = 0.20$

V-A. Cálculo de $D_{KL}(P \parallel Q)$ (en bits, base 2)

Aplicando la definición de la ecuación (1):

$$\begin{aligned} D_{KL}(P \parallel Q) &= 0.90 \cdot \log_2 \left(\frac{0.90}{0.80} \right) + 0.10 \cdot \log_2 \left(\frac{0.10}{0.20} \right) \\ &= 0.90 \cdot \log_2(1.125) + 0.10 \cdot \log_2(0.5) \\ &\approx 0.90 \cdot (0.1699) + 0.10 \cdot (-1.0000) \\ &= 0.1529 - 0.1000 = 0.0529 \text{ bits} \end{aligned} \quad (9)$$

Interpretación: El clasificador genera un costo extra o penalización promedio de apenas ≈ 0.0529 bits por correo debido a su discrepancia con la realidad.

V-B. Demostración Numérica de la Asimetría

Si invertimos el orden de las distribuciones calculando $D_{\text{KL}}(Q \parallel P)$:

$$\begin{aligned} D_{\text{KL}}(Q \parallel P) &= 0.80 \cdot \log_2 \left(\frac{0.80}{0.90} \right) + 0.20 \cdot \log_2 \left(\frac{0.20}{0.10} \right) \\ &= 0.80 \cdot (-0.1699) + 0.20 \cdot (1.0000) \\ &= -0.1359 + 0.2000 = 0.0641 \text{ bits} \end{aligned} \quad (10)$$

Como se observa claramente:

$$D_{\text{KL}}(P \parallel Q) = 0.0529 \text{ bits} \neq D_{\text{KL}}(Q \parallel P) = 0.0641 \text{ bits} \quad (11)$$

lo que demuestra numéricamente que la divergencia KL no es una distancia simétrica.

VI. CONCLUSIONES Y RECOMENDACIONES

La Divergencia de Kullback–Leibler unifica la cuantificación de información con la optimización de sistemas predictivos modernos.

Recomendaciones técnicas:

1. **Evitar probabilidades nulas:** Implementar suavizado de Laplace o un valor mínimo $\varepsilon > 0$ en las salidas softmax para eludir divergencias numéricas a infinito.
2. **Alternativas simétricas:** Cuando se requiera una distancia formal y acotada entre distribuciones, se sugiere emplear la divergencia de Jensen–Shannon (JSD) o la distancia de Wasserstein [4].

VII. INCERTIDUMBRES Y LIMITACIONES

- **Continuidad absoluta:** La divergencia KL está indefinida si el soporte de P no está estrictamente contenido en el soporte de Q .
- **No métrica:** No satisface la desigualdad triangular ni la simetría métrica.
- **Vulnerabilidad ante sesgos:** Minimizar la divergencia KL en datos de prueba no inmuniza al sistema contra sesgos de selección o cambios de dominio (*distribution shift*).

DECLARACIÓN SOBRE EL USO DE INTELIGENCIA ARTIFICIAL GENERATIVA

Uso de GenAI: Se declara explícitamente que la redacción, estructuración matemática y codificación $\text{\LaTeX}$ bajo estándar IEEE de este artículo fueron elaboradas con el soporte de herramientas de Inteligencia Artificial Generativa, contando con revisión conceptual y validación técnica humana.

REFERENCIAS

- [1] S. Kullback and R. A. Leibler, “On information and sufficiency,” *The Annals of Mathematical Statistics*, vol. 22, no. 1, pp. 79–86, 1951. <https://projecteuclid.org/journals/annals-of-mathematical-statistics/volume-22/issue-1/On-Information-and-Sufficiency/10.1214/aoms/1177729694.short>
- [2] T. M. Cover and J. A. Thomas, *Elements of Information Theory*, 2nd ed. Hoboken, NJ: John Wiley & Sons, 2006.
- [3] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY: Springer, 2006.

- [4] Y. Wang, H. Zhang, and L. Liu, “Generalized Kullback–Leibler divergence loss,” *arXiv preprint arXiv:2503.08038*, 2026. <https://arxiv.org/html/2503.08038v2>
- [5] Wikipedia Contributors, “Kullback–Leibler divergence,” *Wikipedia, The Free Encyclopedia*, 2026. https://en.wikipedia.org/wiki/Kullback%E2%80%93Leibler_divergence